Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

UNIVERSITE MOHAMMED V

École Nationale Supérieure d'Informatique et d'Analyse des Systèmes

Compte Rendu

TP1 de Jeux et Video GD 2025 2026 N°1

Réalisé par :

Zakariae BELLIL

Aymane EL AKKIOUI

Filière : GD

2025-2026

1. Objectif du TP

L'objectif de ce TP est de découvrir la bibliothèque **Gymnasium** à travers deux environnements différents, **Taxi-v3** et **MiniGrid-Empty-16x16-v0**, puis de construire progressivement plusieurs politiques de contrôle, allant d'une politique aléatoire à des politiques plus guidées par des heuristiques ou par une mémoire minimale. Le but n'était pas d'obtenir un agent optimal, mais de comprendre le fonctionnement d'un environnement Gymnasium, la structure des observations, et la manière de coder une politique explicite

Partie A — Découverte de Taxi-v3

Dans cette première partie, nous avons créé l'environnement Taxi-v3 et observé ses principaux éléments : action_space, observation_space, spec et unwrapped. Nous avons également exécuté quelques actions aléatoires afin d'observer le comportement de la fonction step().

Réponses aux questions

1. Quel est le nombre d'actions possibles ?
L'environnement Taxi-v3 possède **6 actions** possibles : se déplacer vers le sud, le nord, l'est, l'ouest, effectuer pickup et effectuer dropoff.

2. Que représente l'observation dans Taxi-v3 ?
L'observation est un **état discret encodé par un entier**. Cet entier représente la position du taxi, la position du passager et la destination.

3. Pourquoi cet environnement est-il adapté à une première étude de politique ?
Taxi-v3 est adapté à une première étude car :

- l'espace d'actions est réduit ;
- l'état est compact et facilement décodable ;
- les règles de l'environnement sont simples ;
- il est possible de concevoir rapidement une politique explicite.

Partie B — Politique aléatoire sur Taxi-v3

Nous avons implémenté une politique entièrement aléatoire, puis exécuté plusieurs épisodes afin de mesurer la récompense totale, le nombre d'étapes et le taux de succès.

Réponses aux questions

1. Pourquoi les performances de cette politique restent-elles faibles ?
Les performances restent faibles car l'agent choisit ses actions sans logique. Il se déplace souvent inutilement, effectue pickup ou dropoff au mauvais moment et accumule ainsi des pénalités.

2. Quelles actions inutiles ou coûteuses apparaissent fréquemment ?
Les actions les plus coûteuses sont surtout :

- pickup effectué alors que le passager n'est pas sur la case ;
- dropoff effectué alors que le taxi n'est pas à destination ;

- des déplacements aléatoires qui rallongent inutilement l'épisode.

Partie C — Politique aléatoire contrainte sur Taxi-v3

Dans cette partie, nous avons amélioré la politique aléatoire en filtrant certaines actions manifestement invalides lorsque l'information disponible le permettait.

Réponses aux questions

1. Pourquoi un simple filtrage des actions peut-il améliorer les résultats ?
Le filtrage améliore les résultats car il évite les actions les plus manifestement erronées, notamment les pickup et dropoff invalides. Cela réduit les pénalités inutiles.

2. En quoi cette politique reste-t-elle malgré tout limitée ?
Elle reste limitée car, même si elle évite certaines erreurs grossières, elle ne sait toujours pas planifier un trajet cohérent vers le passager ou la destination. Les déplacements restent essentiellement aléatoires.

Partie D — Politique heuristique simple pour Taxi-v3

Nous avons ensuite décodé l'état de l'environnement afin de récupérer les informations utiles et d'écrire une politique guidée : aller vers le passager, faire pickup, aller vers la destination, puis faire dropoff.

Réponses aux questions

1. Quels éléments d'observation sont nécessaires pour construire cette politique ?
Il faut connaître :

- la position du taxi ;
- la position du passager ;
- la destination ;
- l'état indiquant si le passager est déjà dans le taxi.

2. Quels cas particuliers doivent être traités explicitement ?
Il faut traiter :

- le cas où le taxi est déjà sur la case du passager ;
- le cas où le passager est déjà embarqué ;
- le cas où le taxi est arrivé à la destination ;
- les obstacles ou murs internes qui empêchent certains déplacements directs.

Bilan

Cette politique est nettement meilleure que les précédentes, car elle exploite explicitement la structure de l'état. Elle montre que lorsque l'environnement est simple et lisible, une politique codée à la main peut être très efficace.

Partie E — Découverte de MiniGrid-Empty-16x16-v0

Nous avons créé l'environnement MiniGrid-Empty-16x16-v0, observé la structure de l'observation, ses clés disponibles et l'espace d'actions, puis affiché une frame avec le rendu rgb_array.

Réponses aux questions

1. Pourquoi MiniGrid est-il plus difficile à lire directement que Taxi ?
MiniGrid est plus difficile car l'observation n'est pas un simple état discret. Elle est plus riche et moins immédiatement interprétable, avec notamment une représentation locale de l'environnement.

2. Qu'est-ce qui change du point de vue de l'observation et de l'exploration ?
Dans MiniGrid, l'agent ne dispose pas d'une représentation aussi simple que dans Taxi. L'exploration devient plus difficile, car l'espace est plus grand, l'information est plus locale, et le but n'est pas directement atteint par une simple lecture de l'état.

Partie F — Politique aléatoire sur MiniGrid

Nous avons implémenté une politique aléatoire dans MiniGrid et mesuré la récompense cumulée, la longueur des épisodes et le taux de réussite.

Réponses aux questions

1. Pourquoi l'aléatoire devient-il très inefficace dans une grille 16×16 ?
L'aléatoire est très inefficace car la grille est plus grande, le nombre de positions possibles est plus élevé, et la probabilité d'atteindre le but par hasard devient faible.

2. Quel rôle joue la rareté de la récompense ?
La récompense étant rare, l'agent reçoit peu d'indications sur la qualité de ses actions. Cela rend l'exploration aléatoire très peu informative.

Partie G — Politique réflexe minimale sur MiniGrid

Nous avons conçu une politique simple à base de règles locales, par exemple avancer si possible, sinon tourner.

Réponses aux questions

1. Pourquoi une politique purement réflexe peut-elle tourner en rond ?
Parce qu'elle réagit uniquement à la situation immédiate sans mémoire ni vision globale. Elle peut donc répéter les mêmes séquences d'actions sans progresser réellement.

2. Quelles informations manquent pour prendre de meilleures décisions ?
Il manque principalement :

- une mémoire des positions déjà visitées ;
- une représentation plus globale de l'environnement ;
- une stratégie explicite de progression vers l'objectif.

Partie H — Politique d'exploration avec mémoire minimale

Nous avons ajouté une mémoire légère à la politique afin de limiter les répétitions immédiates et de rendre l'exploration plus cohérente.

Réponses aux questions

1. En quoi l'ajout d'une mémoire change-t-il la nature de la politique ?
La politique n'est plus purement réflexe. Elle devient partiellement dépendante de l'historique récent, ce qui lui permet d'éviter certains retours inutiles et de structurer davantage son exploration.

2. Quels gains observez-vous sur les indicateurs quantitatifs ?
Nous observons une amélioration nette du comportement : moins de répétitions, meilleure cohérence des trajectoires, et une meilleure capacité à atteindre l'objectif par rapport à la politique aléatoire ou purement réflexe.

10. Partie I — Comparaison finale

Le TP demandait de comparer toutes les politiques testées, puis de comparer Taxi-v3 et MiniGrid selon plusieurs critères

Tableau récapitulatif synthétique

Environnement	Politique	Reward moyenne	Succès	Observation globale
Taxi-v3	Aléatoire	-790.167	0 %	Très inefficace, nombreuses actions invalides
Taxi-v3	Heuristique	7.840	100 %	Politique cohérente et efficace
MiniGrid	Aléatoire	0.000	0 %	Errance importante, exploration inefficace
MiniGrid	Mémoire minimale	0.976	100 %	Exploration plus organisée et plus stable

Réponse à la question

Quel environnement semble le plus adapté pour introduire les politiques explicites ? Pourquoi ?
L'environnement le plus adapté est **Taxi-v3**, car son état est simple, compact et facilement décodable. Il permet donc de construire une politique explicite claire et efficace plus facilement que MiniGrid.

Questions de synthèse

1. Qu'est-ce qu'une politique dans le contexte de ce TP ?
Une politique est une règle de décision qui associe une observation à une action.

2. Pourquoi Taxi-v3 permet-il de construire plus facilement une politique heuristique explicite ?
Parce que l'état est discret, lisible et contient directement les informations utiles à la décision.

3. Pourquoi MiniGrid-Empty-16x16-v0 rend-il l'exploration plus difficile ?
Parce que l'environnement est plus grand, l'observation est moins directement interprétable, et l'objectif est plus difficile à atteindre sans mémoire ni stratégie.

4. Qu'avez-vous appris sur les limites des politiques codées à la main ?
Les politiques codées à la main peuvent fonctionner dans des environnements simples, mais elles deviennent rapidement limitées dès que l'environnement devient plus riche, plus grand ou moins directement lisible.

Extension — Analyse visuelle

L'extension consistait à observer les politiques à travers des images et des vidéos pour compléter l'analyse quantitative

Réponses aux questions

1. Quels comportements répétitifs, hésitations ou blocages remarquez-vous ?
Les politiques aléatoires et réflexes présentent des déplacements répétitifs, des hésitations et parfois des trajectoires circulaires.

2. Quelle politique paraît la plus cohérente à l'observation ?
La politique heuristique sur Taxi-v3 et la politique avec mémoire minimale sur MiniGrid sont les plus cohérentes visuellement.

3. Le rendu visuel confirme-t-il les indicateurs quantitatifs obtenus auparavant ?
Oui. Les vidéos et frames confirment que les politiques les plus structurées sont aussi celles qui obtiennent les meilleurs résultats quantitatifs.